## **Exercise Text Classification**

June 29, 2019

## 1 Text Classification

24828

10093

17

120

In dieser Aufgabe werden Sie eine Text Classification Pipeline bauen, die Partei gegeben einen Text vorhersagt. Statt der Parlamentsdebatten koennen Sie auch gerne einen anderen Text Datensatz nehmen, wenn Sie einen guten finden. Stellen Sie aber sicher, dass Ihre Kollegen Zugriff auf die Daten haben fuer die Korrektur.

```
In [1]: #!pip install pandas
In [2]: import os, gzip
        import pandas as pd
        import numpy as np
        import urllib.request
        import warnings
        warnings.filterwarnings('ignore')
        DATADIR = "data"
        if not os.path.exists(DATADIR):
            os.mkdir(DATADIR)
        file_name = os.path.join(DATADIR, 'bundestags_parlamentsprotokolle.csv.gzip')
        if not os.path.exists(file_name):
            url_data = 'https://www.dropbox.com/s/1nlbfehnrwwa2zj/bundestags_parlamentsprotoko
            urllib.request.urlretrieve(url_data, file_name)
        df = pd.read_csv(gzip.open(file_name), index_col=0).sample(frac=1)
  Ein Auszug der Parlamentsdebatten
In [13]: df[:4]
Out[13]:
                sitzung wahlperiode
                                             sprecher \
         42752
                    234
                                  18 Dr. ăAndré Hahn
         13898
                    159
                                  17
                                        Jimmy Schulz
```

17 Kerstin Griese

Dennis Rohde

18

```
text partei
42752 Frau Präsidentin! Meine Damen und Herren! Durc... linke
13898 Natürlich gibt es Probleme bei der Ausbildung ... fdp
24828 Wir alle wissen doch: Meistens trifft es die S... spd
10093 Insofern ist meine Entscheidung auch frauenpol... spd
```

Splitten Sie die Daten in Train (80%) und Test (20%), dafuer koennen sie die sklearn train\_test\_split function benutzen.

Dann trainieren Sie eine Pipeline mit einem geeigneten Vectorizer und einem sklearn Modell Ihrer Wahl.

Vergleichen Sie die Precision/Recall/F1 und Accuracy auf dem Train und Test set.

```
In [3]: from sklearn.feature_extraction.text import TfidfVectorizer
        from sklearn.model_selection import train_test_split, GridSearchCV
        from sklearn.neighbors import NearestCentroid
        from sklearn.linear_model import SGDClassifier
        from sklearn.pipeline import Pipeline
        from sklearn.metrics import confusion_matrix, classification_report
In [4]: # split data and labels into train and test data, train and test labels
        train_data, test_data, train_labels, test_labels = train_test_split(df['text'], df['par
                = TfidfVectorizer(max_features = int(1e8))
                                                                                 # construct fe
In [14]: ncc
                 = NearestCentroid()
                                                                                  # construct N
         ncc_clf = Pipeline([('vect', vect),('clf', ncc)])
                                                                                  # construct P
         ncc_clf.fit(train_data, train_labels)
                                                                                  # train pipel
         ncc_predictions = ncc_clf.predict(test_data)
                                                                                  # predict lab
         ncc_clf_report = classification_report(ncc_predictions, test_labels)
                                                                                  # create repo
         print(ncc_clf_report)
              precision
                           recall f1-score
                                              support
      cducsu
                   0.48
                             0.63
                                       0.54
                                                  2479
                             0.19
         fdp
                   0.38
                                       0.25
                                                  1402
                             0.32
                                       0.35
      gruene
                   0.39
                                                 1541
       linke
                   0.56
                             0.36
                                       0.44
                                                  1829
                   0.27
                             0.44
                                       0.34
                                                 1485
         spd
                                                 8736
    accuracy
                                       0.41
                   0.42
                             0.39
                                       0.38
                                                  8736
  macro avg
weighted avg
                   0.43
                             0.41
                                       0.41
                                                  8736
```

```
logreg_predictions = logreg_clf.predict(test_data)
logreg_clf_report = classification_report(logreg_predictions, test_labels)
print(logreg_clf_report)
```

	precision	recall	f1-score	support
cducsu	0.90	0.56	0.69	5197
fdp	0.06	0.65	0.10	60
gruene	0.30	0.63	0.41	614
linke	0.66	0.59	0.62	1291
spd	0.39	0.59	0.47	1574
accuracy			0.58	8736
macro avg	0.46	0.60	0.46	8736
weighted avg	0.73	0.58	0.62	8736

```
In [5]: from sklearn.neighbors import KNeighborsClassifier
```

knc = KNeighborsClassifier(3)

knc\_clf = Pipeline([('vect', vect), ('clf', knc)])

knc\_clf.fit(train\_data, train\_labels)

knc\_predictions = knc\_clf.predict(test\_data)

knc\_clf\_report = classification\_report(knc\_predictions, test\_labels)

print(knc\_clf\_report)

	precision	recall	f1-score	support
cducsu	0.79	0.44	0.57	5792
fdp	0.16	0.21	0.18	521
gruene	0.14	0.40	0.21	444
linke	0.15	0.56	0.24	335
spd	0.32	0.45	0.37	1644
accuracy			0.43	8736
macro avg	0.31	0.41	0.32	8736
weighted avg	0.61	0.43	0.48	8736

```
In [6]: from sklearn.tree import DecisionTreeClassifier
    dtc = DecisionTreeClassifier(max_depth=5)
    dtc_clf = Pipeline([('vect', vect), ('clf', dtc)])
    dtc_clf.fit(train_data, train_labels)

dtc_predictions = dtc_clf.predict(test_data)
```

dtc\_clf\_report = classification\_report(dtc\_predictions, test\_labels)
print(dtc\_clf\_report)

	precision	recall	f1-score	support
cducsu	0.83	0.46	0.59	5858
fdp	0.05	0.40	0.09	83
gruene	0.11	0.42	0.17	325
linke	0.20	0.66	0.30	369
spd	0.31	0.34	0.33	2101
accuracy			0.44	8736
macro avg	0.30	0.46	0.30	8736
weighted avg	0.64	0.44	0.49	8736

In [14]: from sklearn.ensemble import AdaBoostClassifier

```
adc = AdaBoostClassifier()
adc_clf = Pipeline([('vect', vect), ('clf', adc)])
adc_clf.fit(train_data, train_labels)
```

adc\_predictions = adc\_clf.predict(test\_data)
adc\_clf\_report = classification\_report(adc\_predictions, test\_labels)
print(adc\_clf\_report)

	precision	recall	f1-score	support
cducsu	0.77	0.52	0.62	4808
fdp	0.13	0.60	0.22	146
gruene	0.25	0.38	0.30	819
linke	0.46	0.45	0.45	1278
spd	0.30	0.42	0.35	1685
accuracy			0.48	8736
macro avg	0.38	0.47	0.39	8736
weighted avg	0.58	0.48	0.51	8736